MEMORIA FINAL DEL NOTEBOOK

Asistente Conversacional de Tenerife con RAG y Function Calling

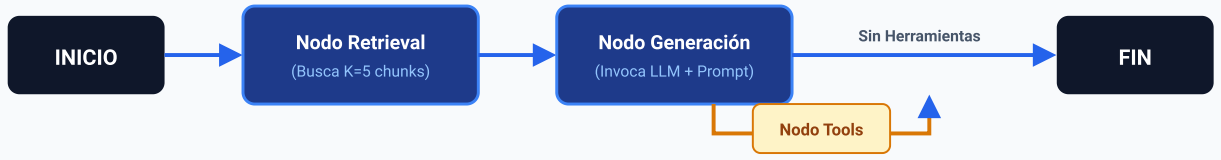
ASIGNATURA
Large Language Models

AUTOR
David García Valeriano

INSTITUCIÓN
Pontia Tech

1. Esquema del Grafo en LangGraph

El flujo del asistente se orquesta mediante un grafo de estado que coordina la recuperación documental y la activación de herramientas externas:



2. Pilares Técnicos Desarrollados

1. Búsqueda RAG Precisa
Indexación de la guía en PDF para responder sobre sitios que ver y comer sin alucinaciones.

2. Flujo en LangGraph
Orquestación agéntica del grafo conectando la memoria y la evaluación de herramientas.

3. Historial Multiturno
Atención a preguntas encadenadas usando directamente el historial de mensajes de la sesión.

4. Consulta de Clima (Tool)
Obtención del tiempo actual en tiempo real mediante la integración de la API de Open-Meteo.

3. Notas de Desarrollo e Implementación

- **Estructura y Chunking del PDF:** Tras revisar la guía de Tenerife, se comprobó que el contenido estaba dividido entre zona norte y sur, separando visitas y gastronomía. Se añadieron metadatos a los fragmentos (sección, zona, página) para permitir un filtrado directo antes de la búsqueda por similitud.
- **Ajuste del Parámetro K:** Se realizaron pruebas modificando el número de fragmentos recuperados (probando con K igual a 1, 2, 4 y 5). Un valor de K igual a 5 resultó ser el más equilibrado para no omitir recomendaciones en consultas de carácter general sobre una zona.
- **Orquestación con LangGraph:** La integración de LangGraph requirió ajustar el flujo entre los nodos para que la llamada a la herramienta del tiempo coexistiera de forma transparente con las respuestas del RAG.
- **Gestión del Historial Conversacional:** El diálogo multiturno se resolvió pasando el historial completo en cada invocación, logrando que preguntas cortas como *"¿Y para comer?"* o *"¿Están buenos?"* mantengan siempre el contexto previo.

4. Function Calling (Herramienta Meteorológica)

La función `get_current_weather` se decoró como herramienta y se enlazó al modelo. Implementa la resolución en dos pasos: geocodificación con la API de Open-Meteo para obtener latitud y longitud, y posterior consulta de las condiciones meteorológicas actuales. Cuando se detecta una pregunta sobre el clima, se limpia el contexto RAG para priorizar la respuesta de la herramienta.

5. Bucle de Pruebas Ejecutado en el Notebook

En el notebook se probó una secuencia continuada de 9 preguntas multiturno en un mismo hilo para validar la solidez del flujo:

#	Pregunta en el Notebook	Respuesta / Comportamiento Observado	Resultado
1	*¿Qué sitios ver en la zona norte?*	Filtra zona norte y recupera itinerario con fuentes (pág. 1-2).	RAG Correcto
2	*¿Y para comer?*	Entiende el contexto de la zona norte y muestra los guachinches.	Multiturno OK
3	*¿Están buenos?*	Hace referencia directa a los comentarios de los sitios listados.	Coherente
4	*Algún plato*	Destaca batatas, almogrote, arepas y bocadillos descritos en la guía.	Preciso
5	*¿Y en el sur?*	Cambia la búsqueda a la zona sur (Los Gigantes, Siam Park, etc.).	Cambio Zona
6	*¿Qué tiempo hace en Santa Cruz?*	Llama a Open-Meteo y devuelve temperatura y viento actuales.	Function Call
7	*¿Sitios obligatorios?*	Retoma el hilo de Santa Cruz y resume los puntos principales.	Recupera RAG
8	*¿Qué playas visitar?*	Muestra recopilación de playas de norte a sur.	RAG Global
9	*¿Qué ver en Orotava?*	Recupera los detalles específicos de La Orotava de la guía.	Detalle Fino

6. Observaciones y Limitaciones Identificadas

- **Uso de Vector Store en Memoria:** Para el alcance de este notebook se utilizó un almacén vectorial en memoria. Funciona correctamente con esta guía, pero para un entorno en producción requeriría almacenamiento persistente.
- **Generación sin Streaming:** Las respuestas del grafo en LangGraph se reciben de golpe al finalizar la ejecución del nodo de generación, sin transmisión progresiva de tokens.
- **Límite de Tiempo en el Desarrollo:** Por limitaciones de tiempo no se exploraron alternativas más avanzadas como clasificadores automáticos de intenciones ni arquitecturas multiagente.

> **Conclusión de las Pruebas:** El flujo implementado en el notebook resuelve de forma estable la combinación de RAG, memoria conversacional y function calling, cumpliendo con los puntos requeridos en la práctica.